

Protocole d'Extraction de Données - PRED-IRM (GBM)

Ce document détaille la procédure et le format **strict** requis pour l'extraction des données d'imagerie (IRM T1-gado) et des données clinico-démographiques associées.

Le respect absolu de ce protocole est impératif pour garantir l'intégrité et l'exploitabilité de la base de données. Aucune déviation de la structure de fichiers ou du format du manifest ne sera acceptée.

1. Objectif et Livrables

L'objectif est d'extraire deux composants pour chaque patient :

1. **L'IRM T1-gado** (volume complet).
2. **Les métadonnées** (cliniques, survie, technique) **impérativement** renseignées dans un fichier unique `manifest.xlsx`.

La localisation de la tumeur (GBM) ne doit **pas** être fournie sous forme de masque de segmentation. Elle doit **uniquement** être spécifiée par les index de la première et de la dernière coupe où la tumeur est visible, directement dans le fichier `manifest.xlsx`.

Le livrable final est un dossier unique `data/` structuré comme décrit à la section 2.

2. Structure Stricte des Fichiers

Le dossier `data/` à livrer doit impérativement respecter l'arborescence suivante.

Bash

```
data/
├── manifest.csv
├── MR/
│   ├── CAL_1234/
│   │   ├── 1-1.dcm
│   │   ├── 1-2.dcm
│   │   └── ...
│   ├── CAL_1235/
│   │   └── ...
│   └── ...
└── ...
```

Exigences de la structure :

- **data/** : Dossier racine.

- **manifest.xlsx** : Fichier Excel (ou CSV) unique, **placé à la racine** du dossier data/. Ce fichier centralise toutes les métadonnées.
- **MR/** : Dossier unique contenant les volumes IRM.
- **MR/{subject_id}/** : Chaque patient doit avoir son propre sous-dossier, nommé exactement par son `subject_id` (défini dans le manifest). Ce dossier contient toutes les images DICOM de la série T1-gado.

⚠ Avertissement : La présence de tout autre fichier ou dossier (notamment des dossiers RT/ ou des masques NIfTI) à la racine est interdite.

3. Le Fichier `manifest.xlsx`

Ce fichier est la pierre angulaire de l'extraction. Il doit contenir **exactement** les colonnes décrites ci-dessous, dans l'ordre spécifié.

Un fichier modèle (`manifest_template.xlsx`) est fourni avec ce protocole et doit être utilisé comme base de travail.

3.1 Description des Colonnes

Colonne	Description	Format	Obligatoire	Notes
<code>subject_id</code>	Identifiant unique du sujet.	string	Oui	Format strict : <code>{id_center_FL}_{id_local}</code>
<code>mr_path</code>	Chemin relatif vers le dossier IRM.	path	Oui	Ex: <code>./MR/CAL_00001/</code> (voir Règle 3.2.2)
<code>survival_days</code>	Survie globale en jours.	integer	Conditionnel	Voir Règle 3.2.1 (Survie)
<code>idx_first_GBM</code>	Index (base 1*) de la 1ère coupe où le GBM apparaît.	integer	Oui	Sur le plan axial
<code>idx_end_GBM</code>	Index (base 1) de la dernière coupe où le GBM apparaît.	integer	Oui	Sur le plan axial
<code>manufacturer</code>	Fabricant de l'équipement IRM.	string	Oui	(0008, 0070). Ex: SIEMENS

Colonne	Description	Format	Obligatoire	Notes
manufacturer-model	Modèle de l'équipement IRM.	string	Oui	(0008, 1090). Ex: Skyra
age	Âge du patient (au moment de l'examen).	string	Oui	Format DICOM : 054Y. (0010, 1010)
sexe	Sexe du patient.	string	Oui	M, F ou 0. (0010, 0040)
magnetic_field_strength	Intensité du champ magnétique.	float	Oui	En Tesla. Ex: 1.5, 3. (0018, 0087)
acquisition_date	Date de l'examen IRM.	string	Conditionnel	Format ISO YYYY-MM-DD. Voir Règle 3.2.1
death_date	Date du décès du patient.	string	Conditionnel	Format ISO YYYY-MM-DD. Voir Règle 3.2.1

* base 1 : si c'est indiqué coupe 44, il faut prendre la coupe 44.

3.2 Règles de Saisie Impératives

3.2.1 Règle de Survie (Critique)

Pour chaque patient, l'information de survie doit être fournie d'une des deux manières suivantes (exclusion mutuelle) :

- **Option A :** Renseigner survival_days (si le calcul Date décès - Date acquisition est déjà effectué). Dans ce cas, acquisition_date et death_date peuvent être laissées vides (N/A).
- **Option B :** Renseigner **obligatoirement** acquisition_date **ET** death_date. Dans ce cas, survival_days doit être laissé vide (N/A).

3.2.2 Règle des Chemins (Critique)

1. **Chemins Relatifs Uniquement :** Tous les chemins dans la colonne mr_path **doivent** être relatifs à l'emplacement du fichier manifest.xlsx (c'est-à-dire à la racine du dossier data/).
2. **Chemins Absolus Interdits :** Les chemins absolus (ex: C:\Users\Utilisateur\Documents\... ou /home/user/projets/...) sont **strictement interdits** et invalideront l'extraction.

3. **Format** : Utiliser des slashes (/) comme séparateur de dossier. Le chemin doit pointer vers le *dossier* contenant les DICOMs.

- Format requis : ./MR/{subject_id}/

3.2.3 Gestion des Valeurs Manquantes

Pour toute colonne non-obligatoire (ou conditionnelle non-remplie), la cellule doit contenir la valeur N/A ou être laissée vide.

3.3 Exemple de Manifest Conforme

	A	B	C	D	E	F	G	H	I	J	K	L
1	subject_id	mr_path	survival_days	idx_first_GBM	idx_end_GBM	manufacturer	manufacturer-model	age	sexe	magnetic_field_strength	acquisition_date	death_date
2	CAL_00001	./MR/CAL_00001/				SIEMENS	Skyra					
3	CAL_00002	./MR/CAL_00002/				PHILIPS	Ingenia					
4	CAL_00003	./MR/CAL_00003/				GE MEDICAL SYSTEMS	DISCOVERY MR750					

4. Conventions de Nommage (subject_id)

L'identifiant subject_id est la clé unique. Il doit être construit comme suit :
f"{id_center_FL}_{id_local}"

- id_center_FL : Identifiant unique du centre (voir table ci-dessous).
- id_local : Identifiant local du patient sur 4 ou 5 chiffres (ex: 00001), anonymisé.

Centre	id_center_FL
Nice	CAL
Rouen	CHB
Caen (Baclesse)	CFB
Grenoble	CHUGA
Nancy	ICL

5. Annexe : Tags DICOM de Référence

Pour extraire les informations requises pour le manifest. (Uniquement si vos données DICOM sont encore non anonymisées, sinon il faut aller se référer à votre logiciel d'exportation des données pour récupérer ces informations).

Information	Tag DICOM
Date de l'acquisition (acquisition_date)	(0008, 0022)
Sexe du patient (sexe)	(0010, 0040)
Âge du patient (age)	(0010, 1010)
Fabricant (manufacturer)	(0008, 0070)

Information	Tag DICOM
Modèle du fabricant (manufacturer-model)	(0008, 1090)
Intensité du champ magnétique (magnetic_field_strength)	(0018, 0087)
Date du décès (death_date)	Non-DICOM (Doit provenir du dossier patient / DPI)

```

data/
├── manifest.csv
├── MR/
│   ├── CAL_1234/
│   │   ├── 1-1.dcm
│   │   ├── 1-2.dcm
│   │   └── ...
│   ├── CAL_1235/
│   │   └── ...
│   └── ...

```

Optionnel : Ajouts d'autres modalités

Vous pouvez ajouter une autre modalité en suivant la logique du protocole en ajoutant une colonne nommée "flair_path" par exemple si vous souhaitez ajouter une modalité FLAIR .